Análisis y Ciencia de Datos
Tarea 3: Introducción a Series de Tiempo

Facultad de Ingeniería, Universidad del Istmo de Guatemala

Fecha de entrega: 25 de octubre de 2026, 11:59PM

---

1 Introducción

Hasta ahora casi todos nuestros datos han sido *intercambiables*: si barajamos las filas de `Auto`, nada cambia. En una serie de tiempo el orden *es* la información. Lo que pasó ayer dice algo de lo que pasa hoy, los lunes no se parecen a los domingos, y el futuro no está disponible para entrenar.

La tarea tiene dos mitades. En la primera (Parte 0) vamos a construir el vocabulario con datos que ustedes mismos simulan y donde conocemos la respuesta. En la segunda vamos a trabajar con datos de verdad, y los datos de verdad vienen sucios: todas las transacciones de una tienda en línea del Reino Unido durante un año. Vamos a limpiarlos, a entender su estructura, a pronosticarlos y, al final, a mirar a los clientes que hay detrás de la serie.

¿Y esto para qué nos sirve?

En la industria, alguien les va a pedir "el pronóstico de ventas del próximo trimestre" o "¿quiénes son nuestros mejores clientes?" y les va a pasar una tabla parecida a la de esta tarea. Nadie les va a decir que las facturas que empiezan con `C` son cancelaciones, ni que la tienda cierra los sábados. Quien sabe limpiar, agregar y validar una serie de tiempo sin engañarse a sí mismo vale mucho más que quien sabe llamar a `.fit()`.

Además, esta tarea les deja una parte del proyecto hecha, en el cual vamos a comparar un pronóstico construido cliente por cliente contra uno construido sobre la serie agregada.

2 Un poco de teoría

Esta sección se apoya en dos libros que vale la pena tener a la mano. *Forecasting: Principles and Practice* [3] (FPP2) es gratis en línea y muy práctico: si tienen que leer uno solo, que sea este. *Analysis of Financial Time Series* [4] es más formal y está escrito para finanzas;

su capítulo 2 es la mejor referencia corta de la teoría lineal. Cuando una idea aparece en alguno de los dos, les dejo la sección.

Una serie de tiempo es un proceso estocástico

Una variable aleatoria Y es un número que todavía no conocemos. Un **proceso estocástico** es una colección de variables aleatorias indexadas por el tiempo,

$$\{Y_t : t = 1, 2, 3, \dots\},$$

y lo nuevo es que ahora nos importa la distribución *conjunta*: cómo se relaciona Y_t con Y_{t-1}, con Y_{t-7}, etc. La venta de mañana es una variable aleatoria; la venta de todo el próximo año es un proceso.

Lo que observamos, $y_1, y_2, \dots, y_n$, es **una sola realización** del proceso. Esto es raro si lo piensan: en todo el curso hemos estimado cosas a partir de muchas observaciones independientes de la misma distribución, y aquí tenemos una observación de cada Y_t. La única salida es suponer que el proceso tiene cierta regularidad en el tiempo, para que promediar a lo largo del tiempo sirva como promediar sobre muchas realizaciones. Esa regularidad se llama estacionariedad (técnicamente hace falta además ergodicidad, pero no nos vamos a preocupar por eso aquí).

Sin saberlo, utilizamos (o incluso implementamos) procesos estocásticos cada vez que generamos números pseudoaleatorios en nuestras computadoras. Ahí, el proceso que *queríamos* era el más aburrido posible, $Y_t \overset{\text{iid}}{\sim} \text{Unif}(0, 1)$.

Estacionariedad y autocorrelación

FPP2 lo dice en una línea: una serie es estacionaria si sus propiedades no dependen del momento en que se observa [3, §8.1]. Tsay [4, §2.1] distingue dos versiones. La *estricta* pide que la distribución conjunta de cualquier tramo $(Y_{t_1}, \dots, Y_{t_k})$ sea igual a la del mismo tramo desplazado en el tiempo; es demasiado exigente para verificarla con datos. La que usamos en la práctica es la **débil**: un proceso es **débilmente estacionario** si su media y su varianza no cambian con el tiempo, y si la covarianza entre dos momentos solo depende de qué tan separados están:

$$E[Y_t] = \mu, \qquad \text{Var}(Y_t) = \sigma^2, \qquad \text{Cov}(Y_t, Y_{t-k}) = \gamma_k \quad \text{para todo } t.$$

La **función de autocorrelación** (ACF) es $\rho_k = \gamma_k / \gamma_0$: la correlación entre el proceso y él mismo k pasos atrás. Con datos la estimamos con:

$$r_k = \frac{\sum_{t=k+1}^{n} (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{n} (y_t - \bar{y})^2}.$$

Si el proceso es ruido blanco (iid con varianza finita), entonces para n grande $r_k \approx \mathcal{N}(0, 1/n)$ para cada $k \geq 1$. De ahí salen las bandas $\pm 1.96/\sqrt{n}$ que dibuja cualquier gráfica de ACF. [3, §2.8–2.9], [4, §2.2].

Probar muchos rezagos a la vez

Mirar 20 rezagos contra sus bandas tiene un problema que ya conocen: con 20 pruebas al 5 %, esperamos que una se salga por pura suerte. Las **pruebas portmanteau** juntan los primeros m rezagos en un solo estadístico. La más usada es la de **Ljung–Box**,

$$Q(m) = n(n+2)\sum_{k=1}^{m} \frac{r_k^2}{n-k},$$

que bajo ruido blanco se distribuye aproximadamente como χ^2_m [4, §2.2], [3, §3.3]. Es una prueba χ^2 como las que ya conocen: si las r_k son pequeñas, Q es pequeño. Cuando se aplica a los residuos de un modelo con K parámetros estimados, los grados de libertad bajan a $m-K$ [4, §2.4]. ¿Cuántos rezagos usar? Los dos libros no se ponen de acuerdo: FPP2 recomienda $m = 10$ sin estacionalidad y $m = 2s$ con estacionalidad de periodo s (sin pasar de $n/5$); Tsay cita simulaciones que favorecen $m \approx \log(n)$. Para efectos de esta tarea, prueben ambos y comparen sus resultados.

¿Por qué las series de tiempo casi siempre reprueban?

Con un generador de pseudoaleatorios, queríamos comprobar independencia entre los números generados, es decir, que el generador *pase* la prueba. Con una serie de tiempo real, esto casi nunca pasa, y hay dos razones muy distintas:

(1) **Memoria.** Lo de hoy depende de lo de ayer. Esa es la dependencia que queremos modelar.

(2) **La media no es constante.** Si hay tendencia o estacionalidad, $\bar{y}$ no es la media de nadie: los días de la parte alta de la tendencia quedan todos arriba de $\bar{y}$ y sus vecinos también, así que r_k sale grande aunque no haya ninguna memoria. La prueba supone estacionariedad y reprueba porque el supuesto es falso.

Hay una pista visual para la razón (2): la ACF de una serie no estacionaria baja *despacio*, mientras que la de una serie estacionaria cae a cero rápido [3, §8.1]. Distinguir (1) de (2) es la mitad del trabajo con series de tiempo, y la receta clásica es: primero quitar la tendencia y la estacionalidad, y después mirar qué memoria le queda al residuo.

El modelo AR(1)

El modelo más sencillo con memoria dice que hoy es una fracción de ayer, más una sorpresa:

$$Y_t = c + \phi\, Y_{t-1} + \varepsilon_t, \qquad \varepsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2).$$

Noten que es una regresión lineal donde el predictor es la misma variable un paso atrás, así que ya saben estimarla: OLS de y_t contra y_{t-1}. El parámetro ϕ controla cuánto dura la memoria. Con $\phi = 0$ es ruido blanco; con ϕ cerca de 1, un choque de hoy tarda mucho en

olvidarse; con $\phi = 1$ es una **caminata aleatoria**, $Y_t = Y_{t-1} + \varepsilon_t$, que nunca olvida nada. La motivación práctica es que muchas cosas se comportan así: la temperatura de hoy se parece a la de ayer y una empresa que vendió mucho esta semana probablemente venda bien la próxima [4, §2.4], [3, §8.3].

Las finanzas dan el ejemplo más famoso. El precio de una acción se parece mucho a una caminata aleatoria: el de mañana es el de hoy más ruido. Si eso es cierto, el *rendimiento* (el cambio de precio) es ruido blanco y no se puede pronosticar. Tsay [4, §2.2] lo prueba con Ljung–Box sobre rendimientos mensuales: los de IBM pasan ($Q(5) = 5.4$, $Q(10) = 14.1$, con valores-p de 0.37 y 0.17), mientras que los del índice ponderado por valor del mercado no ($Q(5) = 27.8$, $Q(10) = 36.0$): el índice conserva un poco de autocorrelación, así que la caminata aleatoria es una buena aproximación, no una ley. Noten la idea, porque la vamos a usar en la Parte 4: **diferenciar** (pasar de precios a cambios) convierte una caminata aleatoria en ruido blanco. Por eso el pronóstico de una caminata aleatoria es simplemente el último valor observado, que es el pronóstico "naive" de la clase de validación [3, §8.1, §3.1].

3 Parte 0: Procesos simulados (15 puntos)

0.1 A mano. Supongan que el AR(1) es estacionario con $|\phi| < 1$. Usando que $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-1})$ y que ε_t es independiente del pasado, muestren que:

$$E[Y_t] = \frac{c}{1-\phi}, \qquad \mathrm{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2}, \qquad \rho_k = \phi^k.$$

Para la caminata aleatoria ($\phi = 1$, $c = 0$, $Y_0 = 0$), muestren que $\mathrm{Var}(Y_t) = t\sigma^2$. ¿Por qué eso la hace no estacionaria?

0.2 Simulación. Escriban una función que simule $n = 300$ pasos de un AR(1) con $c = 0$ y $\sigma = 1$ (descarten los primeros 200 pasos para que el valor inicial no importe; para $\phi = 1$ eso no lo logra, ¿por qué no afecta a r_k?). Para $\phi \in \{0, 0.5, 0.9, 1\}$, grafiquen una realización de cada uno. Luego hagan 5 000 réplicas de cada ϕ (con una semilla distinta por escenario) y reporten en una tabla: el promedio de r_1, el promedio de r_5 contra el valor teórico ϕ^5, la fracción de réplicas en que $|r_1| > 1.96/\sqrt{n}$ (la tasa de rechazo de la prueba de ruido blanco) y el promedio del estimado OLS de ϕ. Con 5 000 réplicas, reporten también el error estándar de cada promedio.

0.3 Para $\phi = 0$, ¿la tasa de rechazo es la que esperaban? ¿Por qué? Para la caminata aleatoria, ¿qué pasa con r_5 comparado con la teoría $\phi^5 = 1$? ¿Es consistente el estimado OLS de ϕ con el verdadero, o ven un sesgo? Si lo ven, ¿cómo cambia con ϕ?

0.4 Las dos razones para reprobar. Ahora simulen procesos *sin* memoria, $Y_t = m_t + \varepsilon_t$ con ε_t iid $\mathcal{N}(0, 1)$, para dos medias m_t que cambian con el tiempo:

(a) una tendencia lineal que sube de 0 a 2 a lo largo de los 300 pasos, $m_t = 2t/300$;

(b) un patrón semanal: $m_t = -1.5$ si $t \bmod 7 = 6$ y $m_t = 0.25$ en los demás días.

Repitan la tabla del inciso 0.2 (tasa de rechazo con r_1), y agreguen el promedio de r_7. ¿Cuál reprueba la prueba de retardo 1 aunque no tenga memoria? ¿Cuál la *pasa* aunque tenga estructura? Conecten el segundo caso con RANDU en la Tarea 2: ¿qué tienen en común?

0.5 La prueba que sí ve. Para $\phi = 0$ y para los dos procesos de 0.4, reporten la tasa de rechazo de Ljung–Box con $m = 10$ al 5 % (pueden usar `statsmodels.stats.diagnostic.acorr_ljungbox` para verificar su propia implementación). ¿Qué cambia respecto a la prueba de retardo 1? ¿Por qué?

4 Los datos

Usaremos **Online Retail** [1, 2]: todas las transacciones de una tienda en línea del Reino Unido que vende artículos de regalo, casi todo a mayoristas, entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011. Son unas 540 000 líneas de factura. Hay devoluciones, duplicados, cobros que no son ventas, días en que la tienda no abrió y un par de pedidos que no deberían existir. Descarguen `Online Retail.xlsx` del repositorio de UCI. Cada fila es una línea de factura:

Columna	Descripción
`InvoiceNo`	Número de factura. Si empieza con `C`, es una cancelación.
`StockCode`	Código del producto.
`Description`	Nombre del producto.
`Quantity`	Unidades en la línea.
`InvoiceDate`	Fecha y hora de la factura.
`UnitPrice`	Precio unitario en libras esterlinas (£).
`CustomerID`	Identificador del cliente.
`Country`	País del cliente.

Un consejo antes de empezar: lean `InvoiceNo`, `StockCode` y `CustomerID` como texto. Averigüen por qué.

5 Parte 1: Limpieza

La variable que vamos a pronosticar es la **venta neta diaria**: la suma de `Quantity` × `UnitPrice` de todas las líneas de un día, con las cancelaciones restando el día en que ocurren. Antes de sumar nada, tienen que decidir qué líneas cuentan como venta.

1.1 Carguen los datos y reporten cuántas filas, facturas, productos y clientes hay. ¿Qué fracción de las filas no tiene `CustomerID`?

1.2 Investiguen cada uno de estos casos. Para cada uno, decidan si la línea se queda, se va o se transforma, y justifiquen la decisión en una o dos oraciones:

(a) Filas duplicadas exactas.

(b) Facturas que no empiezan con un dígito. (Hay más de un prefijo.)

(c) Códigos de `StockCode` que no son productos. Pista: miren la descripción de los códigos que no empiezan con cinco dígitos. No todos son iguales: algunos sí son productos.

(d) Precios iguales a cero o negativos.

(e) Cantidades negativas en facturas que *no* son cancelaciones. Lean la columna `Description` de esas filas.

(f) Filas sin `CustomerID`. Ojo: para la serie de ventas la pregunta es distinta que para la Parte 6, donde necesitamos saber quién compró.

1.3 Construyan una **bitácora de limpieza**: una tabla con una fila por regla, el número de filas que elimina y el monto (en £) que esas filas representaban. El orden en que aplican las reglas cambia los conteos, así que reporten el orden.

1.4 Encuentren las seis líneas con mayor $|\texttt{Quantity} \times \texttt{UnitPrice}|$ *antes* de limpiar. Para cada una, cuenten qué pasó (busquen la factura y lo que vino después). ¿Su limpieza las resuelve? ¿Las resuelve el hecho de netear por día?

1.5 Escriban toda la limpieza como una sola función `limpiar(df)` que devuelva el `DataFrame` limpio. La van a reusar en la Parte 6 y en el proyecto.

6 Parte 2: El calendario

2.1 Construyan la serie de venta neta diaria. ¿Cuántos días calendario hay entre el primero y el último, incluyendo ambos? ¿En cuántos hubo al menos una transacción?

2.2 Hagan una lista de los días sin transacciones y clasifíquenlos. ¿Qué día de la semana no abre la tienda? ¿Qué otros días faltan y qué fueron? (Busquen el calendario de *bank holidays* del Reino Unido en 2011. Hay uno que no se repite cada año.) FPP2 [3, §12.1] advierte que los feriados móviles, como la Semana Santa, son de lo más difícil de modelar en datos diarios: ¿cuáles de los que encontraron son móviles?

2.3 ¿Un día sin transacciones es un cero o un dato faltante? Den un uso de la serie en el que debe ser cero y otro en el que debe ser faltante.

2.4 Miren el último día de los datos. ¿Está completo? ¿Qué hacen con él?

De aquí en adelante trabajen con la serie diaria sobre el calendario completo, con los días cerrados marcados como faltantes y sin el último día, salvo que una parte diga otra cosa. Llamamos **entrenamiento** a todo hasta el 30 de septiembre de 2011 y **prueba** a los días abiertos del 3 de octubre al 8 de diciembre de 2011. El domingo 2 de octubre es el primer origen de la prueba: sirve de historia pero no se evalúa.

7 Parte 3: Tendencia, estacionalidad y autocorrelación

Lo que hacen en 3.1 y 3.2 es una *descomposición clásica multiplicativa*: serie = tendencia × estacionalidad × resto [3, §6.1–6.3].

3.1 Tendencia. Calculen una media móvil *centrada* de 7 días sobre el calendario completo (aquí sí, rellenen los días cerrados con cero). Grafíquenla sobre la serie. ¿Por qué 7 y no 5 ni 30? ¿Por qué centrada? Describan la tendencia en dos o tres oraciones.

3.2 Estacionalidad. Usando solo el entrenamiento, para cada día abierto calculen el cociente y_t/MA_t entre la venta y la media móvil. El *índice estacional* de cada día de la semana es el promedio de esos cocientes. Repórtenlo en una tabla y en una gráfica de barras. ¿Qué días venden más? ¿Por qué el promedio de los seis índices no es 1?

3.3 Autocorrelación. Implementen r_k a mano con `numpy` (la misma función de la Parte 0).

(a) Calcúlenla para $k = 1, \ldots, 21$ sobre los días abiertos del entrenamiento, una fila por día, sin calendario. Grafiquen r_k con las bandas $\pm 1.96/\sqrt{n}$. ¿Cuántos rezagos se salen? ¿Pasa la prueba de retardo 1 de la Tarea 2? ¿En qué rezago está el pico y cuántos días calendario representa? Calculen también $Q(6)$ y $Q(12)$ de Ljung–Box.

(b) Con lo que vieron en la Parte 0, ¿cuánto de esa autocorrelación es memoria y cuánto es media no constante? No tienen que contestarlo con un número todavía; la Parte 4 lo hace.

8 Parte 4: Del AR(1) al SARIMA

Vamos a seguir la receta: quitar la estacionalidad, mirar el residuo y modelar la memoria que quede. En toda esta parte trabajen con los días abiertos del entrenamiento como una fila por día.

4.1 Ajusten por OLS la venta contra variables indicadoras de día de la semana (sin intercepto, una por cada día abierto) y guarden los residuos e_t. Calculen y grafiquen su ACF con bandas. ¿Qué cambió respecto a 3.3? Comparen la forma de esta ACF con las de la Parte 0: ¿decae como ϕ^k, como un AR(1), o se parece más a la del proceso con tendencia? ¿Qué le falta a este modelo?

4.2 Ajusten un AR(1) a los residuos: OLS de e_t contra e_{t-1}. Reporten $\hat{\phi}$. Calculen los residuos de ese AR(1), $u_t = e_t - \hat{c} - \hat{\phi}\, e_{t-1}$, y su ACF. ¿Ya parecen ruido blanco? ¿Qué rezagos siguen fuera de las bandas? Confírmenlo con $Q(6)$ y $Q(12)$ (con un grado de libertad menos, porque estimaron ϕ). ¿Alcanzó un AR(1) para lo que encontraron en 4.1?

4.3 SARIMA. Lo que acaban de ver motiva la familia SARIMA$(p,d,q)(P,D,Q)_s$, que es la herramienta estándar para esto [3, §8.5, §8.9], [4, §2.6–2.8]. En palabras:

- p y P son términos autorregresivos como el AR(1): p mira los rezagos $1, 2, \ldots$ y P mira los rezagos estacionales $s, 2s, \ldots$
- d y D son diferencias: en vez de modelar y_t se modela $y_t - y_{t-1}$ (si $d = 1$), $y_t - y_{t-s}$ (si $D = 1$), o las dos a la vez, $(y_t - y_{t-1}) - (y_{t-s} - y_{t-s-1})$, si ambas valen 1. Diferenciar una caminata aleatoria la convierte en ruido blanco, y ese es el truco para series cuya media se mueve.
- q y Q son términos de promedio móvil: el pronóstico se corrige con los errores de pronóstico recientes, ε_{t-1} (y ε_{t-s} en la parte estacional). Ojo: este "promedio móvil" no tiene nada que ver con la media móvil de 3.1; es un nombre desafortunado que ya no se puede cambiar.

Con el operador de rezago B, definido por $By_t = y_{t-1}$ [3, §8.2], el modelo S2 de abajo se escribe en una línea:

$$(1 - B)(1 - B^6)\,\log y_t = (1 + \theta B)(1 + \Theta B^6)\,\varepsilon_t.$$

Con $s = 12$ y datos mensuales, este es el famoso *modelo de aerolínea*: Box y Jenkins lo usaron para los pasajeros mensuales de una aerolínea, y sigue siendo el primer modelo que se prueba con una serie estacional. Con `statsmodels.tsa.statespace.sarimax.SARIMAX`, ajusten sobre el **logaritmo** de la venta diaria dos modelos con $s = 6$:

- **S1**: SARIMA$(1,0,0)(1,0,0)_6$ con constante;
- **S2**: SARIMA$(0,1,1)(0,1,1)_6$ sin constante.

Pásenle a `SARIMAX` el arreglo de valores (`.values`) y no la serie con fechas, porque las fechas tienen huecos. ¿Por qué $s = 6$ y no 7? ¿Cuándo se rompe esa suposición en estos datos? ¿Por qué el logaritmo? (FPP2 [3, §3.2] explica cuándo conviene transformar.) Revisen que el optimizador haya convergido (`mle_retvals`); si no, suban `maxiter` (por ejemplo, a 500) y comparen los parámetros antes y después. Como ajustan en logaritmo, para volver a libras apliquen `exp()` al pronóstico, sin corrección de sesgo.

4.4 Diagnóstico. Un buen modelo deja residuos que parecen ruido blanco [3, §3.3]. Calculen $Q(6)$ y $Q(12)$ sobre los residuos de S1 (el que sí convergió en 4.3) y de S2 (con $m - 2$ grados de libertad). Para S2, descarten los primeros 7 residuos: las diferencias $(1 - B)(1 - B^6)$ se comen 7 observaciones y esos residuos son artefactos del arranque. ¿Cuál modelo deja residuos de ruido blanco?

4.5 S1 es estacionario y S2 no. Con lo que saben del AR(1) y de la caminata aleatoria, ¿hacia dónde van los pronósticos de S1 a medida que el horizonte crece? ¿Y los de S2?

9 Parte 5: Pronóstico y fuga

El pronóstico se hace como en la vida real: cada domingo, con todo lo observado hasta ese día, pronostican los días abiertos de la semana siguiente. Luego avanzan una semana, reajustan y repiten (el *origen móvil* de la clase de validación). Las reglas exactas, para que podamos medir lo mismo:

- el origen es un domingo, y su venta ya forma parte de lo observado;
- los objetivos son los días abiertos del lunes al domingo siguientes;
- en (b) no se evalúa ningún día después del 30 de septiembre, aunque la última semana quede incompleta; en (c), el último día evaluado es el 8 de diciembre;
- para S1 y S2, que trabajan sobre filas de días abiertos, el horizonte de cada objetivo es su posición entre los días abiertos posteriores al origen (los feriados se conocen de antemano);
- el MAE y el RMSE se calculan juntando todos los días pronosticados, no promediando por semana.

5.1 Además de S1 y S2, implementen estos cuatro modelos:

- **B1**: la media histórica de los días abiertos.
- **B2**: *naive* estacional: el valor del mismo día de la semana abierto más reciente. Es el pronóstico de una caminata aleatoria estacional [3, §3.1, §8.1].
- **M1**: OLS con una tendencia lineal en t y variables indicadoras de día de la semana.
- **M2**: OLS con indicadoras de día de la semana y dos rezagos: y_{t-7} y y_{t-14}. Si alguno cae en un día cerrado, usen el mismo día de la semana abierto más reciente (así, para el 9 de mayo, cuyo lunes anterior y el de hace dos semanas fueron feriados, y_{t-7} es el 18 de abril). Las filas que se quedan sin rezago al inicio de la serie no se usan para ajustar.

¿Por qué M2 puede usar y_{t-7} para pronosticar cualquiera de los siete días siguientes, pero no podría usar y_{t-1}? ¿Cómo le hace S1 para usar el rezago 1 de todas formas? En cada reajuste de S1 y S2 usen la configuración que convergió en 4.3 y verifiquen `mle_retvals['converged']` en cada origen.

5.2 Estimen el MAE y el RMSE de cada modelo de tres formas:

(a) validación cruzada aleatoria de 5 *folds* sobre el entrenamiento (repitan con 10 semillas y reporten media y desviación estándar); solo para B1, M1 y M2;

(b) origen móvil semanal dentro del entrenamiento, con orígenes de mayo a septiembre;

(c) el período de prueba, con origen móvil semanal.

Presenten todo en una sola tabla. ¿Por qué no tiene sentido (a) para B2, S1 y S2? ¿Cuál de (a) y (b) se acerca más a (c)? ¿Alguna se acerca de verdad?

5.3 ¿Qué modelo gana en prueba? Expliquen por qué, con una gráfica de los pronósticos contra la serie real en octubre–diciembre y con su respuesta a 4.4.

5.4 La trampa. Un compañero propone agregar a M2 la media móvil centrada de 7 días de la Parte 3 como predictor, porque "resume la tendencia". Háganlo y reporten (a) y (b). ¿Se ve mejor? Expliquen por qué ese predictor es ilegal, por qué el origen móvil *no* lo detecta si la media móvil se calcula una sola vez sobre toda la serie, y por qué no pueden calcular (c) sin hacer trampa.

5.5 Todas las estimaciones hechas dentro del entrenamiento se quedan cortas frente al error de prueba. Separen dos causas: la que viene de cómo se partieron los datos y la que viene de que la serie cambió. ¿Cuál se arregla con una mejor validación y cuál no? Con un solo año de datos, ¿se puede estimar la estacionalidad anual?

10 Parte 6: Detrás de la serie hay clientes: análisis RFM

La serie agregada no sabe quién compra. El **análisis RFM** es la forma más antigua (y todavía de las más usadas) de segmentar clientes con solo tres números por cliente:

- **R**ecencia: días desde la última compra;
- **F**recuencia: número de facturas de venta distintas;
- **M**onto: venta neta total del cliente.

El artículo que publicó estos datos [2] hace justamente un análisis RFM, así que están en buena compañía.

6.1 Con los datos limpios que tienen `CustomerID`, calculen R, F y M para cada cliente usando **solo** las transacciones anteriores al 1 de octubre de 2011, con la recencia medida a esa fecha. ¿Cuántos clientes hay? ¿Cuántos tienen $M \leq 0$ y qué hacen con ellos? ¿Por qué es importante no usar nada posterior al 1 de octubre?

6.2 Asignen a cada cliente un puntaje de 1 a 5 en cada dimensión por quintiles (en recencia, 5 es el más reciente). Van a tener problemas con F. ¿Por qué? Para que todos tengan los mismos puntajes, desempaten al azar: tomen a todos los clientes de 6.1 (incluidos los de $M \leq 0$) ordenados por `CustomerID` ascendente, barájenlos con `numpy.random.default_rng(2026).permutation` y después usen `pd.qcut(F.rank(method='first'), 5)`. ¿Qué implica esto para dos clientes con la misma F que caen en puntajes distintos?

6.3 Sea $\text{compra}_i = 1$ si el cliente compró entre el 1 de octubre y el 8 de diciembre. Para cada puntaje de R, de F y de M, reporten la fracción de clientes que compró. ¿Cuál de las tres dimensiones separa mejor? Calculen el AUC de R, F y M (con los valores crudos; para R, con el signo invertido) y de la suma de los tres puntajes como clasificadores de compra_i.

6.4 Definan como "campeones" a los clientes con puntaje 4 o 5 en las tres dimensiones. ¿Qué fracción de los clientes son y qué fracción generaron de la venta neta del 1 de octubre al 8 de diciembre de *todos* los clientes con `CustomerID`, incluidos los nuevos?

6.5 ¿Qué fracción de la venta neta del 1 de octubre al 8 de diciembre (de todos los clientes con `CustomerID`, como en 6.4) vino de clientes nuevos, es decir, sin ninguna factura de venta antes del 1 de octubre? ¿Puede un análisis RFM, o cualquier modelo construido cliente por cliente, pronosticar esa venta? Conecten la respuesta con la Parte 5 y con el Proyecto 1. En el vocabulario de FPP2 [3, §10.3–10.4], la Parte 5 es un pronóstico *top-down* (se pronostica el total) y un modelo cliente por cliente es *bottom-up* (se pronostica cada cliente y se suma): ¿cuál de los dos puede ver a los clientes nuevos?

11 Entregables

A Blackboard deberán subir únicamente el link a un repositorio de GitHub que contenga sus soluciones. En el repositorio deberán incluir lo siguiente:

- Documento en `.pdf` y código `.tex` con las derivaciones de 0.1, el análisis de todas las partes, la bitácora de limpieza, todas las figuras y las tablas de las Partes 0, 5 y 6.
- Un notebook (`.ipynb`) o archivos `.py` que corran de principio a fin a partir del `.xlsx` original y reproduzcan todas las cifras del documento con las semillas documentadas. La función `limpiar` debe estar en su propio archivo.
- Un `README.md` corto explicando cómo ejecutar el código.

Sobre el análisis (esto es lo que más pesa en la nota). No hay una única limpieza correcta, así que sus números no van a coincidir exactamente con los de sus compañeros. Se valorará una decisión justificada y documentada, y que cada figura y cada tabla que elaboren tenga una explicación de lo que muestran y por qué.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`

[2] D. Chen, S. L. Sain y K. Guo. Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3):197–208, 2012.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`. Lectura recomendada: caps. 2 (gráficas, autocorrelación, ruido blanco), 3 (métodos sencillos, transformaciones, diagnóstico de residuos), 6 (descomposición) y 8 (estacionariedad y ARIMA).

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005. Lectura recomendada: cap. 2, secciones 2.1–2.8 (estacionariedad, autocorrelación, ruido blanco, modelos AR, MA y ARMA, raíces unitarias y modelos estacionales).